INVESTIGACIÓN EXPERIMENTAL · HPC

Cholesky

De la organización de memoria a la evaluación de MPI frente a LAPACK

Implementación en C · distribución MPI · referencia optimizada

Facultad de Ciencias Exactas y Tecnología · Universidad Nacional de Tucumán
Cátedra de Computación de Alto Rendimiento

21 al 28 de septiembre de 2026

Informe integral | Código, evidencia y resultados reproducibles

Pregunta central

Cuándo distribuir el trabajo reduce el tiempo y cuánto depende esa ventaja del kernel local y de la frontera de medición.

Índice de lectura

1. Resultados principales 3

2. Resumen 4

3. Problema matemático y primera implementación verificable 4

4. La primera decisión cambió al estudiar los accesos a memoria 5

5. Distribuir columnas y conservar trabajo útil 7

6. Ampliar la frontera: entrada, resultado y generación 9

7. La granularidad de propiedad no produjo una mejora estable 9

8. LAPACK local mostró que faltaba eficiencia dentro del kernel 10

9. Consolidación del candidato y repetición local 11

10. Definir el reloj antes de interpretar el speedup 12

11. Transición al clúster: recursos visibles y recursos asignados 13

12. Cruce formal del tiempo de aplicación 14

13. Escalabilidad y beneficio del comando completo 16

14. La referencia optimizada en el clúster 18

15. Comparación final de problemas grandes 19

16. Corrección numérica e integridad de la evidencia 22

17. Condiciones del entorno y límites de atribución 23

18. Conclusiones 23

19. Continuación técnica razonable 24

20. Guía de lectura de la entrega 24

Anexo A. Reconstrucción histórica y procedencia 25

1. Resultados principales

La pregunta experimental es cuándo MPI reduce el tiempo y cuánto depende esa ventaja del cálculo local. Los tres resultados siguientes pertenecen a campañas y relojes identificados; no forman una única curva combinada.

Resultado	Evidencia e interpretación
Primer cruce observado	N=192, P=3: primer tamaño ensayado con mejora descriptiva clara de application_s en el cruce formal del clúster. No es un umbral exacto universal.
El reloj cambia la decisión	Con P=6, la campaña de escalabilidad mejora el comando completo en N=2048 y N=4096; en N=512 y N=1024 la mejora de aplicación no alcanza para ganar en external_s.
LAPACK conserva la ventaja	En factor_s, MPI P=6 tarda 8,58 veces LAPACK de un hilo para N=6144 y 6,25 veces para N=8192. No se observó cruce frente a LAPACK.

Candidato seleccionado: right-looking en double, vector local, columnas 1D cíclicas b=1, generación distribuida y reunión del factor en rango 0.

Condiciones de lectura: experimentos locales y campañas del clúster separados; clúster en un host con cuota agregada de seis CPUs y 24 GiB. Las barras Q1-Q3 describen dispersión de las repeticiones, no intervalos de confianza.

Recorrido del informe: primero se explica el algoritmo y la selección del candidato; después se distinguen relojes y resultados del clúster; el cierre reúne corrección, límites y conclusiones. La reconstrucción histórica se conserva en el anexo A.

2. Resumen

Se estudió cómo el tamaño de una matriz simétrica definida positiva modifica la conveniencia de una implementación secuencial propia, una implementación MPI y una referencia LAPACK/OpenBLAS de un hilo. El trabajo comenzó con la corrección de Cholesky y evolucionó mediante comparaciones controladas de algoritmos, accesos a memoria, propiedad de columnas, generación y fronteras de medición. Las pruebas locales permitieron seleccionar un candidato right-looking en C, con vector auxiliar, distribución 1D cíclica por columnas y generación distribuida. Las campañas posteriores se ejecutaron en el clúster bajo una cuota agregada equivalente a seis CPUs y 24 GiB.

Los resultados muestran una mejora de MPI respecto del secuencial propio para parte de la grilla, pero no una ganancia automática al aumentar los procesos. El primer tamaño ensayado con mejora descriptiva clara de aplicación fue N=192 con P=3. En la campaña de escalabilidad, P=6 aceleró la aplicación en los cuatro tamaños estudiados, mientras que el comando completo solo mejoró en N=2048 y N=4096. La comparación final aisló la fase de factorización: en N=6144 y N=8192, MPI P=6 redujo el tiempo del kernel propio, pero continuó siendo más lento que LAPACK/OpenBLAS de un hilo. No se observó un cruce entre estas dos implementaciones hasta N=8192.

La contribución del proyecto consiste en delimitar esas ganancias y sus condiciones, conservar los resultados negativos y mostrar por qué mejorar el cálculo local y distribuirlo son decisiones complementarias. Las conclusiones corresponden a matrices generadas, versiones concretas y sesiones identificadas. No constituyen una evaluación multinodo ni una comparación con ScaLAPACK.

3. Problema matemático y primera implementación verificable

Para una matriz real simétrica definida positiva A, se busca un factor triangular inferior L con diagonal positiva tal que $A = L\,L^T$. El proyecto calcula el factor; no implementa la solución completa de un sistema Ax=b. La dependencia entre columnas se obtiene de la identidad del producto: el pivote de la columna j depende de contribuciones anteriores y los elementos inferiores utilizan ese pivote.

En la formulación left-looking se calcula l(j,j) como la raíz de a(j,j) menos la suma de cuadrados de la fila ya calculada. Después, cada l(i,j) resta el producto escalar de las partes conocidas de las filas i y j y divide por l(j,j). Right-looking aplica esas contribuciones por adelantado a la región restante: termina una columna y actualiza los elementos todavía no factorizados. Ambas variantes mantienen un trabajo aritmético dominante de orden N^3, aproximadamente $N^3/3$ operaciones; su orden de acceso y sus necesidades de comunicación pueden diferir.

El generador C produce entradas simétricas fuera de la diagonal en [-1,1) y establece a(i,i)=1+sumatoria de valores absolutos fuera de la diagonal de la fila. La simetría y la dominancia diagonal estricta positiva justifican la definición positiva en aritmética exacta. Esta familia facilita repetir el experimento y comprobar la implementación. No cubre matrices arbitrariamente mal condicionadas, matrices dispersas ni entradas procedentes de aplicaciones reales.

La representación es densa, en double, almacenada por filas. La factorización sobrescribe el triángulo inferior; el superior conserva datos que no pertenecen al factor L. La reserva sigue siendo de N^2 elementos, aunque solo el triángulo inferior sea el resultado. Las rutinas rechazan pivotes no positivos o no finitos; su contrato presupone una entrada simétrica. No debe interpretarse ese control de pivotes como una comprobación completa de simetría para entradas externas.

Las pruebas utilizan el ejemplo A=[4,12,-16; 12,37,-43; -16,-43,98], cuyo factor inferior es [2,0,0; 6,1,0; -8,5,3]. También comprueban escalares, identidad, tamaños no redondos, distintas semillas, entradas

indefinidas o semidefinidas y valores no finitos. Un factor alterado deliberadamente permite verificar que la comprobación detecta errores.

$$A = LL^{\mathsf{T}}$$

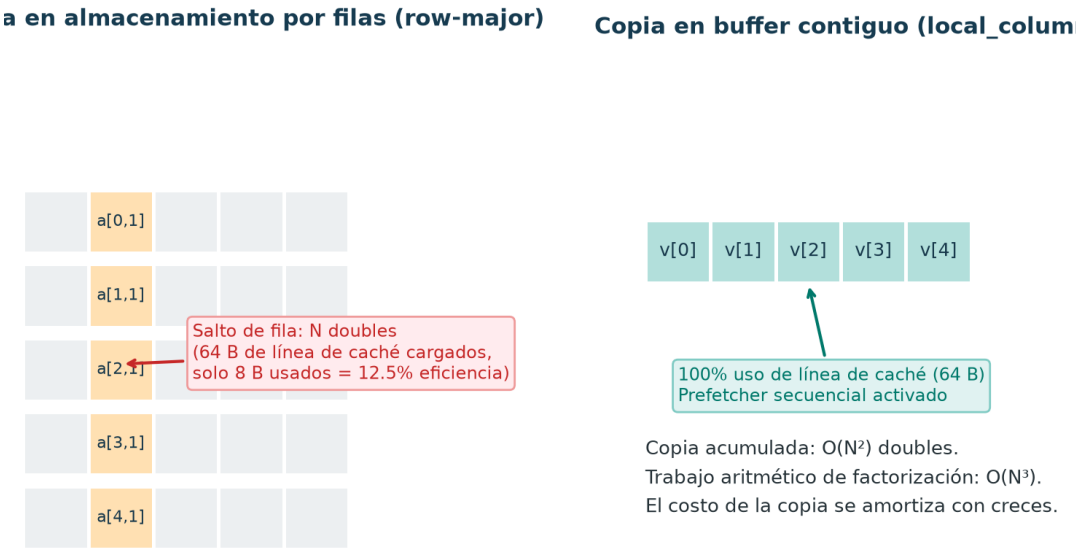
$$l_{jj} = \sqrt{a_{jj} - \sum_{k=0}^{j-1} l_{jk}^2}$$

$$l_{ij} = \frac{a_{ij} - \sum_{k=0}^{j-1} l_{ik} l_{jk}}{l_{jj}} \quad (i > j)$$

4. La primera decisión cambió al estudiar los accesos a memoria

La comparación inicial de left-looking y right-looking en C no respaldó elegir right-looking por velocidad secuencial. Con siete repeticiones por variante, una preparación inicial y orden alternado, left-looking fue más rápido en casi todos los tamaños ensayados. En N=1024 las medianas fueron aproximadamente 137,69 ms para left y 1109,62 ms para right. El reloj incluía solamente la factorización; generación, copia de entrada y reconstrucción quedaban fuera.

La inspección mostró una diferencia concreta: left recorría filas contiguas para sus productos escalares, mientras que el bucle interno de right releía a[k*n+j], una columna con saltos de N elementos. Esto motivó copiar la columna activa a un vector contiguo. El cambio no alteró los propietarios, las dependencias ni las actualizaciones matemáticas; añadió una copia de orden N^2 en una operación cuyo trabajo principal es de orden N^3. La reserva del vector quedó fuera del reloj y su llenado dentro.



Patrón no contiguo: continuos fallos de caché de capacidad/conflicto. Esquema conceptual de jerarquía de memoria; no sustituye contadores PAP

Figura 1. Acceso por columna y copia contigua del kernel secuencial. Esquema conceptual; no representa contadores ni tiempos medidos.

La nueva campaña volvió a medir las tres variantes juntas, sin reutilizar la referencia anterior: seis tamaños, incluida N=1000, doce repeticiones por variante y las seis permutaciones del orden repetidas dos veces. La tabla se recalcula desde memoria_20260921/n*.csv.

N	Left (ms)	Right (ms)	Vector (ms)
64	0.024	0.023	0.020
128	0.200	0.257	0.172
256	1.838	5.816	1.391
512	18.022	185.696	12.325
1000	131.674	95.735	59.854
1024	144.791	1159.089	76.918

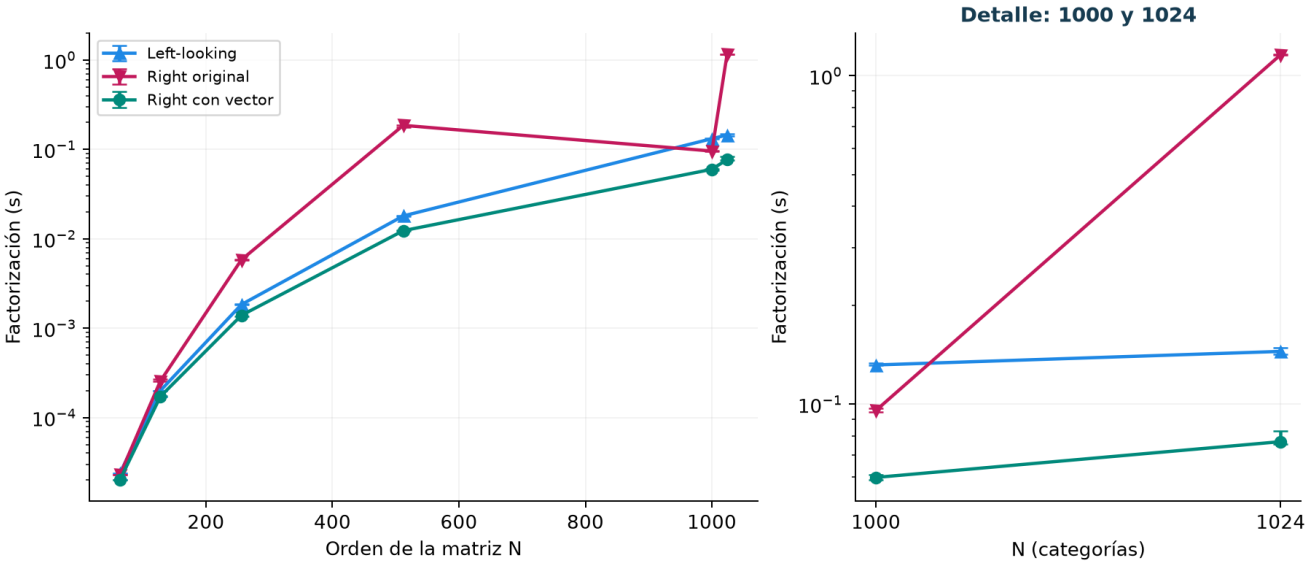


Figura 2. Medianas y Q1-Q3 de la campaña local de memoria, en segundos y escala logarítmica. Cada comparación pertenece a esa misma sesión.

El vector redujo la mediana en todos los tamaños de esa campaña. En N=1024, right original pasó de unos 1159,09 ms a 76,92 ms y también mejoró frente a left, que tardó 144,79 ms en esta sesión. Se eligió right con vector como referencia para desarrollar MPI. La conclusión se refiere a estas implementaciones; no establece la superioridad general de una formulación de Cholesky.

El salto de right original entre N=1000 y N=1024 también aconsejó evitar una interpretación basada solo en el número de operaciones. La organización de accesos era relevante, pero no se midieron contadores que permitieran atribuir la mejora exclusivamente a fallos de caché. La copia también puede modificar la vectorización y las decisiones del compilador.

5. Distribuir columnas y conservar trabajo útil

La primera implementación MPI asignó un propietario fijo a cada columna. El propietario calcula el pivote y el segmento inferior de la columna activa; MPI_Bcast distribuye ese segmento y cada proceso actualiza las columnas futuras que posee. Hay N difusiones durante una factorización completa, con mensajes decrecientes. Las comunicaciones y sus esperas pertenecen al kernel; no se interpretan como latencia pura de red.

Se compararon asignaciones contiguas y cíclicas. En la primera, cada proceso recibe un intervalo de columnas. En la segunda, la columna global j pertenece a j módulo P. Los datos locales se almacenan por filas de columnas propias: local[i*cols+c]. Por tanto, distribución por columnas no significa almacenamiento local column-major.

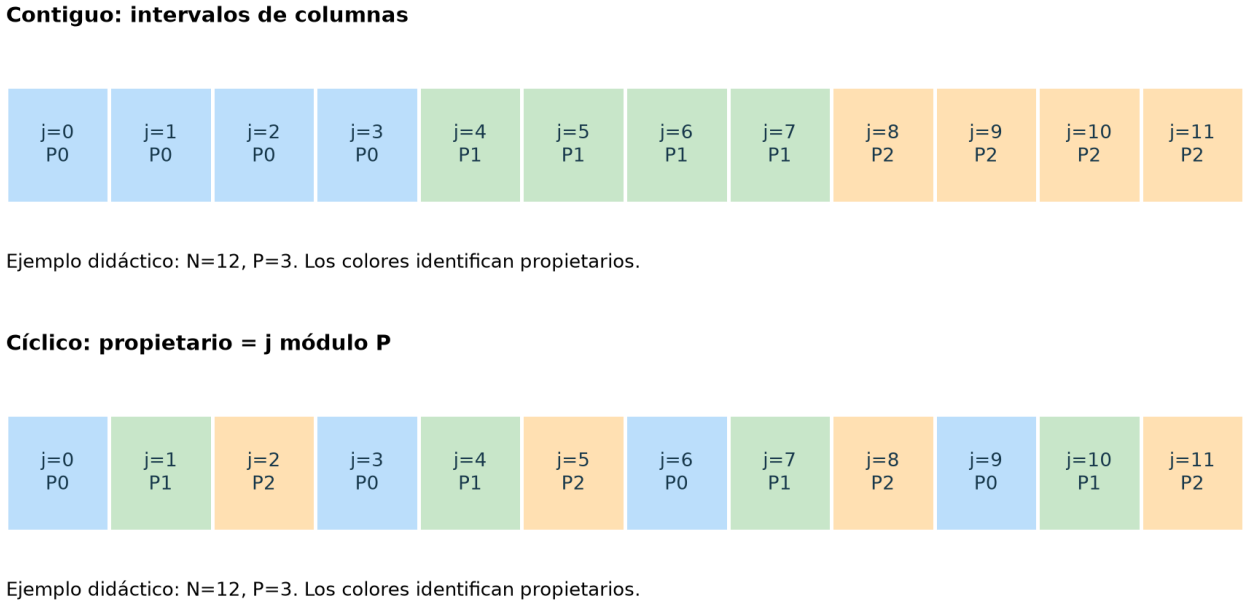


Figura 3. Propiedad contigua y cíclica para N=12 y P=3. En el candidato, el propietario de la columna activa calcula su segmento inferior y lo difunde a todos los procesos mediante MPI_Bcast; cada proceso actualiza sus columnas futuras.

El conteo acumulado de actualizaciones de una columna k es k(N-k). Igual número de columnas no implica igual trabajo ni igual actividad en cada momento. El reparto cíclico mantiene columnas futuras en varios procesos durante más tiempo, pero también introduce indexación y accesos que pueden resultar costosos. El conteo es una explicación estructural; no predice por sí solo el tiempo.

La primera campaña confirmó esa cautela. En N=1024/P=3, el contiguo tuvo una mediana de 40,03 ms y el cíclico de 51,67 ms. La hipótesis favorable al reparto cíclico no bastó para que la primera implementación ganara. Se conservaron ambos resultados y se examinó el acceso interno al vector difundido.

5.1. El vector local cambió el resultado del reparto

El kernel original consultaba column[layout_global(d,c)] en el bucle interno. La variante cholesky_mpi_local reúne primero los valores relevantes en local_column[c]. Esa copia se cobra dentro del kernel y se reutiliza sobre muchas filas. Se mantiene la cantidad de difusiones y el orden de las actualizaciones.

La campaña comparó cuatro variantes: contigua y cíclica, cada una con kernel original o vector local. Ocho repeticiones y un orden balanceado de cuatro variantes permitieron mantener la comparación contemporánea. Para N=1024/P=3:

Reparto y kernel	Mediana (ms)	Q1 (ms)	Q3 (ms)
contiguous:local	39.660	39.128	46.085
contiguous:original	39.615	39.060	51.169
cyclic:local	32.765	30.416	42.178
cyclic:original	72.041	69.947	79.077

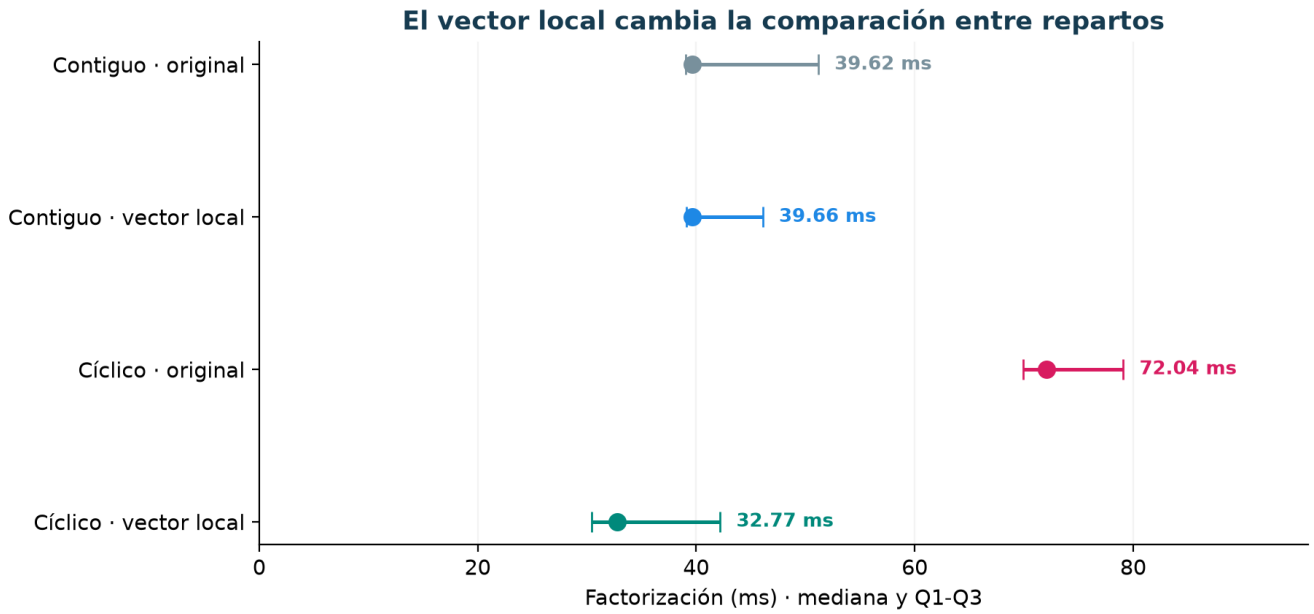


Figura 4. N=1024, P=3, campaña mpi_local_20260921; ocho repeticiones por variante. Punto: mediana; intervalo: Q1-Q3. Datos de summary_all.csv, métrica seconds, cohorte principal local (.).

El cíclico con vector local alcanzó aproximadamente 32,77 ms frente a 72,04 ms del cíclico original medido en esa misma campaña. El contiguo con vector quedó alrededor de 39,66 ms. Así, la elección final del reparto surgió de combinar propiedad de datos y acceso local; no de asumir que una distribución equilibrada debía ser automáticamente más rápida. La referencia secuencial se midió antes y después dentro de la misma campaña.

Las pruebas MPI incluyeron N menor que P, columnas desiguales, factor conocido y fallos colectivos por pivote inválido. El vector local se inicializó con NaN y se rodeó con centinelas para detectar lecturas o escrituras incorrectas. Los perfiles instrumentados se ejecutaron por separado y no reemplazan las mediciones principales sin instrumentación interna.

5.2. El primer cruce local y la comparación de algoritmos MPI

El estudio local del cruce utilizó N=64,96,128,160,192,224,256 y P=1,2,3. Se hicieron tres rondas con distinto orden de tamaños, ocho repeticiones MPI por variante y referencias secuenciales antes y después. Se exigió speedup mayor que 1,10 y Q3 de MPI menor que Q1 del mejor secuencial contemporáneo en las tres rondas. N=256/P=3 cumplió ese criterio; no se generalizó el resultado a otro reloj o máquina. Las tres rondas eran lanzamientos distintos dentro de una sesión, no tres días independientes.

Después se implementó left-looking MPI sobre el mismo reparto cíclico para contrastar la decisión algorítmica. Cada proceso calcula contribuciones con sus columnas anteriores y las reduce al propietario de la columna activa. El código realiza N reducciones escalares, N-1 reducciones vectoriales y N difusiones del pivote: 3N-1 colectivas, frente a N difusiones del right implementado. El conteo corresponde a estos códigos, no a toda implementación posible de left-looking.

En N=1024/P=3, las medianas fueron 54,08 ms para left MPI y 31,48 ms para right con vector local. La campaña alternó los algoritmos y mantuvo distribución y recolección fuera del reloj del kernel. El resultado sostuvo la selección de right dentro del diseño estudiado; no aisló cuánto de la diferencia se debía a colectivas, aritmética o accesos.

6. Ampliar la frontera: entrada, resultado y generación

Medir solo el kernel podía favorecer una solución que requiriera mucho trabajo adicional para preparar y devolver los datos. El siguiente banco definió un caso completo: A comienza en rango 0 y L debe terminar allí. Para MPI se midieron empaquetado y MPI_Scatterv, factorización, MPI_Gatherv y reconstrucción. Para el secuencial se midieron copia y factorización. Reserva, generación y validación todavía estaban fuera.

En N=1024/P=3, right MPI registró medianas de aproximadamente 5,323 ms de entrada, 38,848 ms de factor y 5,630 ms de salida; el total medido directamente fue 49,699 ms frente a 94,523 ms del secuencial de ese banco. No se obtiene ese total sumando medianas: cada fase se redujo por máximo entre procesos y esos máximos pueden corresponder a rangos distintos. En esta grilla el primer tamaño con una mejora total clara pasó a N=512, mostrando que un cruce del kernel no es un cruce del flujo completo.

6.1. Generación distribuida sin cambiar la matriz

La generación centralizada añadía un paso serial y el traslado inicial de la matriz. Se introdujo un generador indexado que reproduce el valor correspondiente a cada par de índices usando la misma secuencia entera y semilla 2026. Cada proceso genera sus columnas y calcula la diagonal sumando los valores absolutos en el orden de índices previsto. El banco contrasta el almacenamiento local contra columnas de la referencia centralizada mediante igualdad bit a bit.

Para N=2048/P=6, generar y distribuir pasó de una mediana de 51,862 ms a 8,385 ms en ese experimento. El resultado no significaba una mejora igual del programa completo: la generación es de orden N^2 y la factorización continúa dominando al aumentar N. Con un solo proceso, la generación distribuida incluso fue más lenta en ese tamaño, lo que se conserva como resultado negativo.

Se amplió entonces el reloj a reserva, generación, eventual distribución, kernel y reunión. En N=2048/P=6, el total centralizado fue 874,604 ms y el distribuido 837,392 ms; la referencia secuencial del mismo banco fue 1617,307 ms. La ganancia del flujo fue menor que la observada al aislar generación. Se adoptó la generación distribuida porque elimina la necesidad de construir y repartir A inicialmente desde rango 0, conservando una comparación numérica verificable. El resultado sigue reuniéndose al final y la validación regenera A en rango 0.

7. La granularidad de propiedad no produjo una mejora estable

Con el flujo completo disponible, se probó asignar grupos de b columnas consecutivas por turnos, con b=1,2,4,8,16,32,64. Cambió el mapa propietario/global/local, pero siguió existiendo una factorización escalar y una difusión por columna. Este experimento de propiedad no implementó paneles, productos matriz-matriz ni un Cholesky bloqueado basado en BLAS-3.

La campaña inicial del 22/09 incluyó N=512,1024,2048, P=1,3,6 y siete repeticiones por variante, con 441 observaciones. b=4 apareció favorable para N=1024/P=6 y se repitió conservando b=1 como

referencia. En nuevos lanzamientos de la misma sesión, las medianas fueron 48,93 y 44,02 ms, respectivamente. En N=2048 la diferencia quedó alrededor de 0,2 %, insuficiente para sostener una ventaja práctica estable.

La confirmación del 24/09 evaluó únicamente b=1 y b=4, con ocho repeticiones alternadas. El resultado cambió:

N	b=1 total (ms)	b=4 total (ms)
1024	42.339	43.359
2048	767.989	798.865

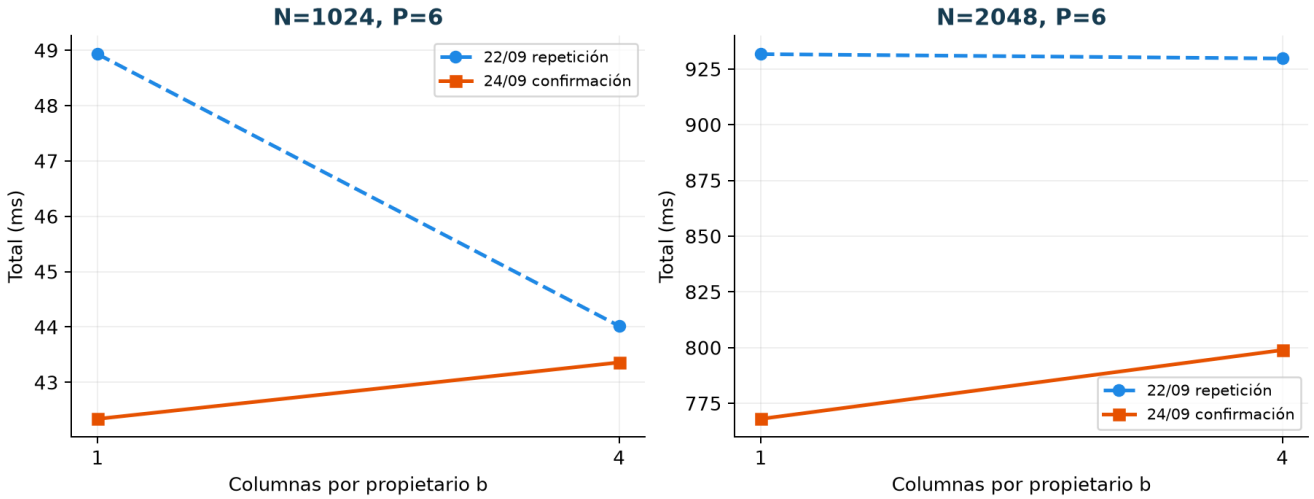


Figura 5. Comparaciones de b dentro de cada sesión, P=6. Las líneas separan la repetición del 22/09 y la confirmación del 24/09; no representan una única muestra combinada.

La ventaja inicial no se sostuvo entre sesiones. Se mantuvo b=1 como configuración principal y se conservó b=4 como alternativa experimental, sin buscar otro mínimo retrospectivo para reemplazarla. N=3072 se probó con dos repeticiones por variante como piloto de factibilidad; no fue una campaña suficiente para seleccionar un reparto.

8. LAPACK local mostró que faltaba eficiencia dentro del kernel

La comparación local incorporó una referencia profesional sin reemplazar la implementación educativa. LAPACK ofrece rutinas de álgebra lineal; DPOTRF calcula Cholesky. Su implementación de referencia utiliza bloques y llamadas BLAS de nivel 3, como operaciones sobre submatrices. LAPACKE proporciona la interfaz C. OpenBLAS aporta implementaciones optimizadas de esas operaciones. La combinación permite reutilización de datos y kernels especializados, pero el experimento no separa la contribución de bloqueo, vectorización, instrucciones, compilación y demás decisiones internas. DPOTRF, Netlib.

compare_lapack.c compara el right con vector propio con LAPACKE_dpotrf_work. Ambos usan double, el mismo generador y la misma semilla. Se fija OpenBLAS a un hilo por API y se verifica con openblas_get_num_threads. En la campaña local ambos métodos compartieron afinidad CPU 0; las versiones registradas fueron LAPACKE 3.12.1 y OpenBLAS 0.3.32.

La matriz simétrica row-major se interpreta como column-major con triángulo superior. El factor U que escribe LAPACK representa $L=U^T$ al leer el arreglo por filas. Esa correspondencia evita una transposición adicional y se comprueba con el factor conocido. La interfaz _work evita la conversión row-major y el

barrido opcional de NaN de la interfaz superior; no vuelve idénticos los contratos de error de ambas rutinas.

Se realizaron seis observaciones útiles por método para N=512,1024,2048, alternando el orden tras una preparación interna. N=3072 tuvo dos y se conserva como piloto. En N=2048, factor_s propio fue aproximadamente 1484,35 ms y LAPACK 116,30 ms: una relación de 12,76. El cociente del total del banco fue 9,74, porque reserva y generación permanecen en el flujo.

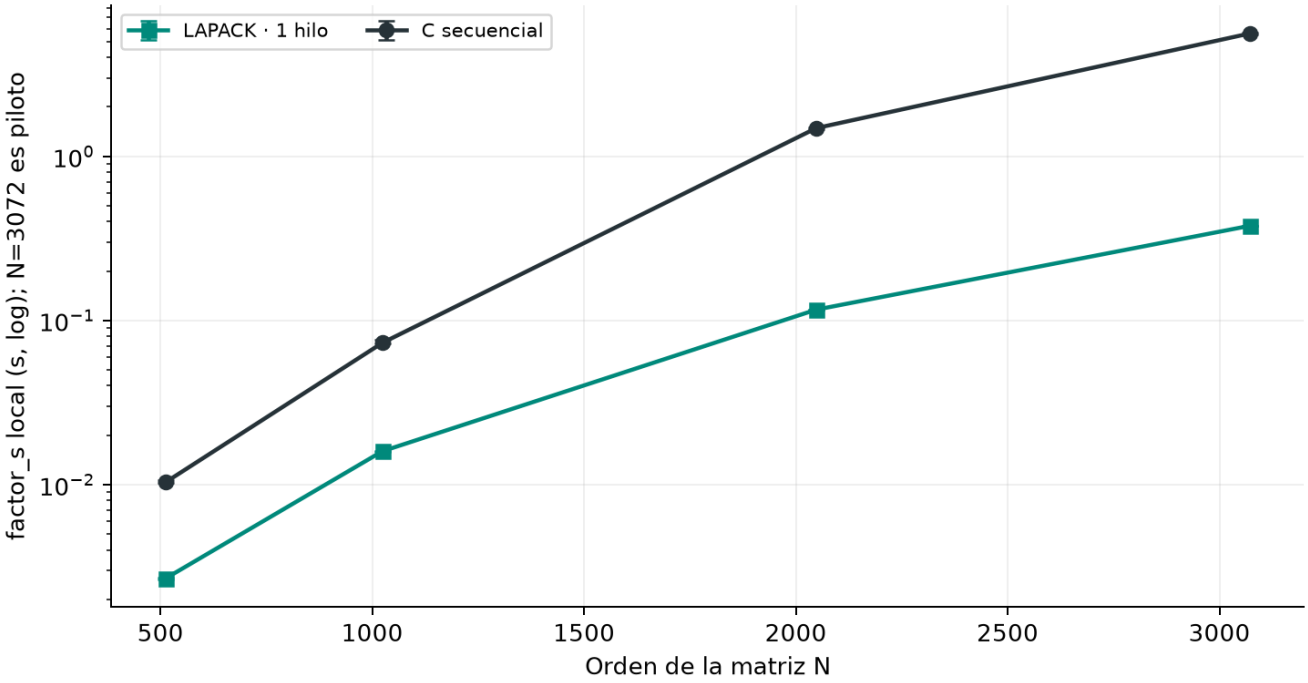


Figura 6. Comparación local C/LAPACK de factorización. N=3072 tiene solo dos observaciones por método y es exploratorio; no se usa para una conclusión formal de escalabilidad.

Esta evidencia motivó considerar la optimización intranodo como una continuación importante. No hizo innecesario estudiar MPI: la biblioteca local y la distribución entre procesos responden a niveles distintos del problema.

9. Consolidación del candidato y repetición local

main_candidate.c reunió las decisiones elegidas en un programa con dos compilaciones. Sin USE_MPI, genera A y ejecuta cholesky_right_buffered; con USE_MPI, genera columnas cíclicas, llama a cholesky_mpi_local y reúne el factor en rango 0. La propiedad es b=1. El candidato no usa OpenMP, no llama a LAPACK y no elige P automáticamente.

Recibe N entre 1 y 20000, utiliza semilla 2026 y devuelve métricas CSV. El límite de interfaz no garantiza que el problema quepa en memoria. La matriz L queda en memoria del rango 0; el programa no lee ni escribe matrices completas a disco. Además del almacenamiento distribuido mantiene buffers completos en rango 0 para reunión y validación, por lo que no representa una implementación de memoria mínima.

Las campañas locales del 24/09 y del 27/09 utilizaron N=256,512,1024,2048 y los métodos secuencial, MPI P=1,2,3,4,6. Cada sesión conservó 192 lanzamientos: 24 preparaciones y 168 observaciones útiles. Hubo siete repeticiones por configuración, rotación de métodos y 30 configuraciones pequeñas de comprobación adicionales. Los tamaños siguieron orden fijo, no una aleatorización completa.

Sesión	Reloj	MPI P6 (s)	Speedup	E (%)
20260924	application_s	0.890	1.825	30.4
20260924	external_s	1.685	1.161	19.4
20260927	application_s	0.906	1.953	32.6
20260927	external_s	1.807	1.159	19.3

La repetición sostuvo la dirección de la mejora para N=2048/P=6, aunque cambiaron los tiempos y el speedup interno. El incremento de recursos no produjo curvas siempre monótonas. Ambas sesiones se conservan separadas; reunirlas como si fueran catorce repeticiones homogéneas ocultaría esa variación.

10. Definir el reloj antes de interpretar el speedup

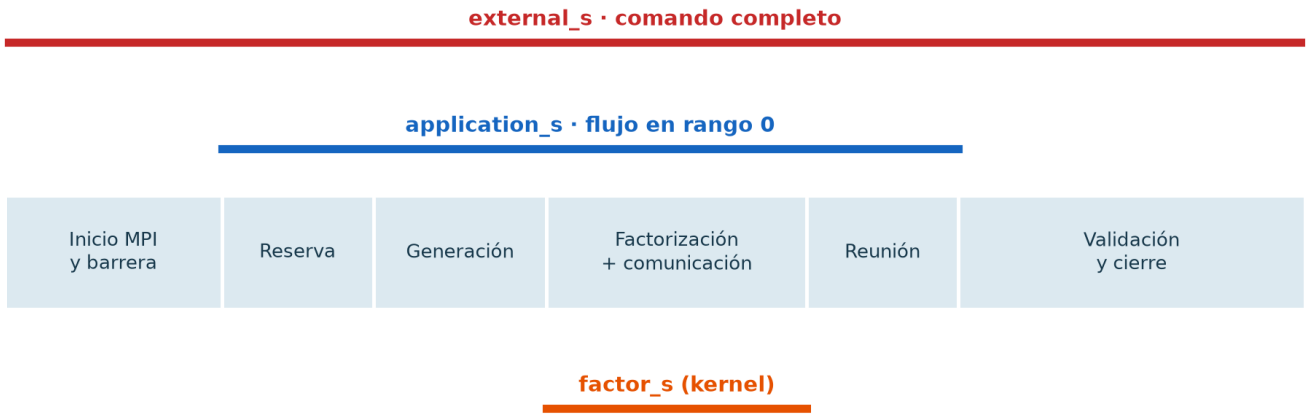


Figura 7. Relojes del candidato MPI, de la fase matemática al comando completo. Los anchos son ilustrativos. La inicialización queda fuera de application_s; la comunicación del kernel queda dentro de factor_s.

El candidato inicia MPI, establece el comunicador y realiza una barrera antes de comenzar el reloj de aplicación. En rango 0, allocation_s, generation_s, factor_s y gather_s son intervalos consecutivos. Su suma por observación coincide con application_s. En MPI, gather_s incluye tanto MPI_Gatherv como la reconstrucción serial del arreglo global en rango 0.

factor_s de MPI es la duración local observada en rango 0 de la llamada al kernel, con comunicaciones y esperas. No es cómputo puro ni un máximo reducido entre todos los rangos. max_local_s registra el máximo de las duraciones locales de todo el flujo, después del reloj principal; no redefine cada una de sus fases. La reducción de tiempos y la combinación del estado de fallo quedan fuera de application_s.

La validación comienza después. Regenera A en rango 0, calcula residuos y comprueba finitud y diagonal positiva; su duración es validation_s. Después se imprime el CSV, se comunica el estado final, se libera memoria y se finaliza MPI. Ni MPI_Init ni MPI_Finalize pertenecen a application_s.

measure_command.c mide con reloj monotónico desde antes de fork hasta el retorno de waitpid. El hijo ejecuta el comando completo mediante execvp; para MPI, ese comando incluye mpirun. Su CSV contiene external_s y el código de salida. El reloj incluye inicialización, programa, validación, salida y

cierre; excluye escribir el CSV del cronómetro. Tampoco incluye arrancar WSL, obtener una sesión web o esperar en una cola.

Por ello, external_s - application_s no equivale a startup MPI. Si además se resta la validación por observación, todavía quedan inicialización, barreras, reducciones auxiliares, liberación, salida y finalización. No se restan medianas independientes para atribuir esos componentes.

En compare_lapack.c, factor_s abarca la llamada de factorización. total_s incluye reserva, generación y factor, pero excluye la preparación de referencias del banco, validación y liberación. No es el mismo reloj que application_s MPI ni un tiempo externo. En la comparación entre los tres métodos se adopta factor_s como operación común, manteniendo las diferencias de ejecución del banco.

El speedup utilizado es S=mediana(T_secuencial)/mediana(T_MPI), con referencia propia contemporánea. La eficiencia E=S/P compara esa ganancia con el ideal lineal; no mide porcentaje de utilización de CPU. El escalado de una ruta MPI también puede medirse como T_MPI,1/T_MPI,P, que es otro cociente. Variar P con N fijo es escalabilidad fuerte; variar N entre configuraciones no constituye por sí solo un estudio de escalabilidad débil.

$$S = \frac{\text{mediana}(T_{\text{seq}})}{\text{mediana}(T_{\text{MPI}})} \qquad E = \frac{S}{P}$$

11. Transición al clúster: recursos visibles y recursos asignados

El clúster mostró un AMD EPYC 7B12, dos sockets de 64 núcleos, 128 CPUs visibles y dos dominios NUMA, con cpuset permitido 0-127. Las campañas principales se realizaron bajo cpu.max = 600000 100000, cuota agregada equivalente a seis CPUs por período, y memory.max = 25769803776, equivalente a 24 GiB. Antes se había utilizado una asignación de dos CPUs y 6 GiB durante la preparación.

Ver 128 CPUs o aproximadamente 503 GiB de memoria del host no concedía esos recursos a la sesión. El cpuset indica dónde puede ejecutarse un proceso; la cuota limita el tiempo agregado de CPU del cgroup. No implica seis núcleos exclusivos. La afinidad solicita ubicación y tampoco elimina interferencia del host. El diagnóstico archivado de P=6 muestra ranks en el primer socket, pero no sustituye registros por ejecución ni demuestra la ubicación de páginas de memoria.

El entorno registró GCC 13.3.0, Open MPI 4.1.6 y Python 3.13.11 en la preparación. Las versiones posteriores de bibliotecas se identifican en cada paquete. Los resultados WSL con Ryzen 5 2600 y GCC 15.2.0 no se utilizaron como denominadores del clúster. Se conservaron fuentes con hashes y se compiló en destino.

El paquete preformal permite verificar cinco fuentes, logs de compilación vacíos y 53 CSV originales con salidas de error vacías. Las comprobaciones pequeñas de N=128 mantienen residuo exacto consistente con las pruebas anteriores. Las versiones actuales de los fuentes candidatos coinciden byte a byte con las instantáneas incluidas en las campañas del clúster.

11.1. Pilotos para elegir una campaña acotada

Los ensayos preformales incluyeron tamaños pequeños y N=512,1024,2048,4096. Sirvieron para localizar el régimen de cruce, probar que los tamaños mayores eran ejecutables y observar diferencias entre P=3,4,6. Los escaneos de una observación no se presentan como estimaciones estadísticas equivalentes a una campaña formal.

El control de N=4096/P=6 tuvo tres observaciones por método: alrededor de 10,327 s de aplicación secuencial y 4,123 s MPI. Ese control justificó continuar, pero no reemplazó la campaña posterior. Parte del contexto de afinidad y cgroup solo aparece en la bitácora; el informe distingue esas transcripciones del contenido original del tar. Las tablas reconstruidas inicialmente tenían valores redondeados; para recalcular se utilizan los CSV originales recibidos después.

12. Cruce formal del tiempo de aplicación

Se ensayaron N=128,160,192,224,256 y seis métodos: secuencial y MPI P=1,2,3,4,6. Se conservaron 30 preparaciones y 210 observaciones útiles, siete por configuración. El protocolo anunciado fijaba el secuencial, solicitaba binding para MPI y rotaba el orden. El paquete conserva las rondas y evidencia de entorno, pero no el script original de lanzamiento completo; esa ausencia limita la auditoría de determinadas condiciones.

El criterio descriptivo fijado fue S>1,10 y Q3_MPI<Q1_SEQ. Exige una ganancia de más del 10 % y separación de los intervalos intercuartílicos observados. No es un test formal de significancia, no produce p-values y no convierte siete mediciones de una sesión en garantía universal.

P	Primer N ensayado que cumple
1	ninguno
2	256
3	192
4	224
6	256

En N=128 y N=160 ningún P cumplió ambas condiciones. N=192 favoreció P=3; N=224 favoreció P=3 y P=4; en N=256 las cumplieron P=2,3,4,6. La expresión correcta es primer N ensayado: no se midieron todos los tamaños intermedios.

Método	Mediana ms	Q1 ms	Q3 ms	S	E %
seq	2.206	2.177	2.219	1.000	-
p1	2.538	2.480	2.556	0.869	86.9
p2	1.360	1.352	1.374	1.623	81.1
p3	1.121	1.112	1.147	1.968	65.6
p4	1.160	1.154	1.194	1.902	47.6
p6	1.505	1.493	1.508	1.466	24.4

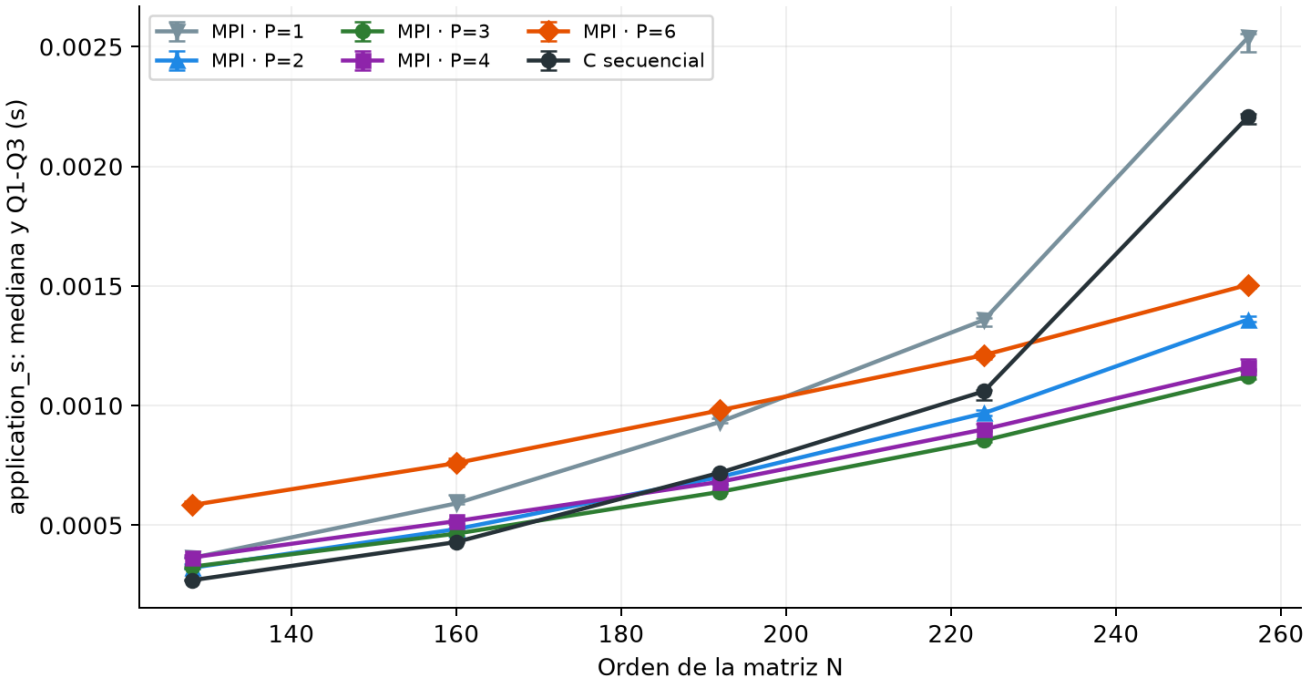


Figura 8. Medianas y Q1-Q3 de aplicación en el cruce formal; siete observaciones por punto, preparaciones excluidas.

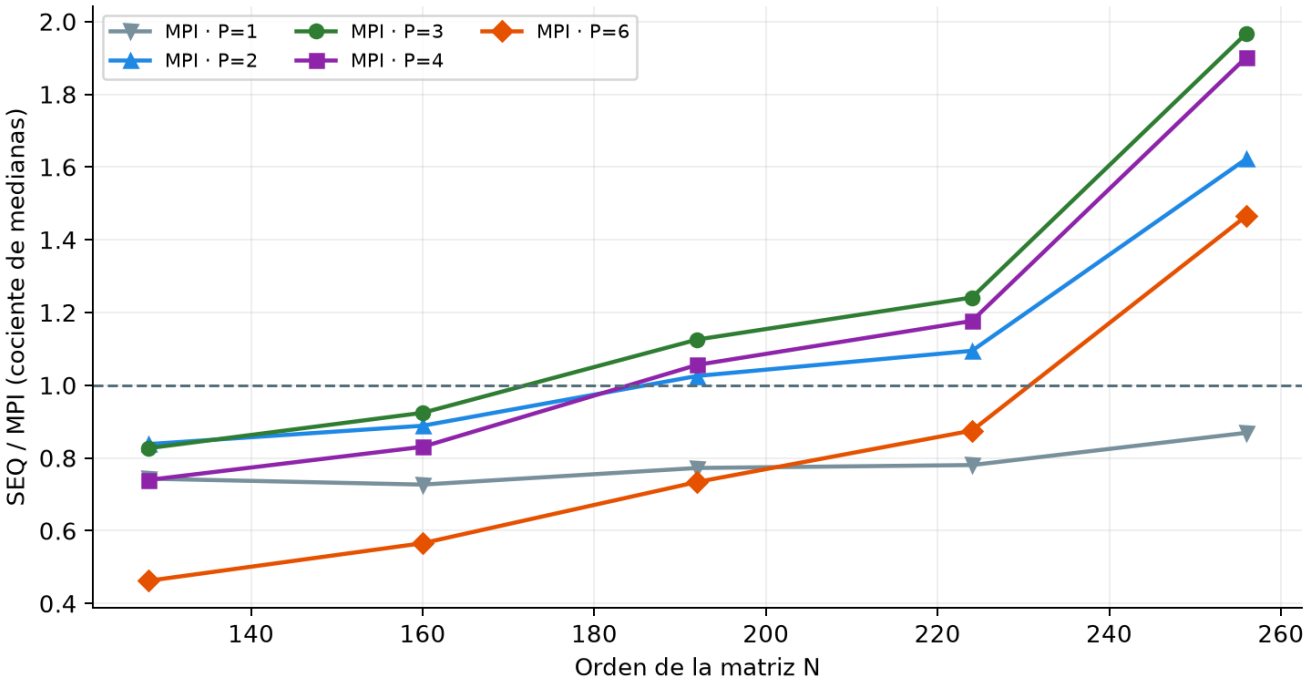


Figura 9. Cocientes de medianas del cruce, cada uno con el secuencial de su mismo N. No son intervalos de confianza.

P=3 tuvo la menor mediana en N=256, mientras que P=2 alcanzó la mejor eficiencia entre las configuraciones que aceleraron. P=6 mejoró al secuencial, pero con una eficiencia menor. No se deduce un P óptimo universal. El MPI P=1 es una ruta con generación distribuida y reunión, no una copia del ejecutable secuencial.

Las fases permiten interpretar el cruce: en N=160/P=3, generación y factor ya reducían su duración respecto de la referencia, pero la reunión todavía compensaba ese ahorro. En N=192/P=3, el balance del flujo fue favorable. Esto es consistente con amortizar los costos adicionales al aumentar trabajo, sin pretender aislar un único mecanismo causal.

Los nombres de archivo acumularon prefijos rep. La explicación registrada fue una asignación rep="$3" en una función Bash sin variable local que afectó al bucle exterior. Los CSV y sus rondas pudieron identificarse inequívocamente; cada configuración conservó siete observaciones. Se preservan los nombres y se añade su correspondencia normalizada. La reparación propuesta usa una variable local distinta; los nombres posteriores están normalizados, pero no se presenta como inspeccionado un script corregido que no se archivó.

13. Escalabilidad y beneficio del comando completo

La campaña siguiente amplió N a 512,1024,2048,4096 y mantuvo P=1,2,3,4,6 y el secuencial. Cada configuración tuvo una preparación y siete observaciones útiles: 168 mediciones y 24 preparaciones. Cada lanzamiento registra simultáneamente el reloj de aplicación y el externo. Los 192 casos tienen valid=1, código de salida cero y salida de error vacía.

N	App P6 (s)	S app	E app %	Ext P6 (s)	S externo
512	0.005	3.228	53.8	0.516	0.059
1024	0.028	3.692	61.5	0.569	0.262
2048	0.197	5.828	97.1	1.046	1.429
4096	4.134	2.514	41.9	6.601	1.873

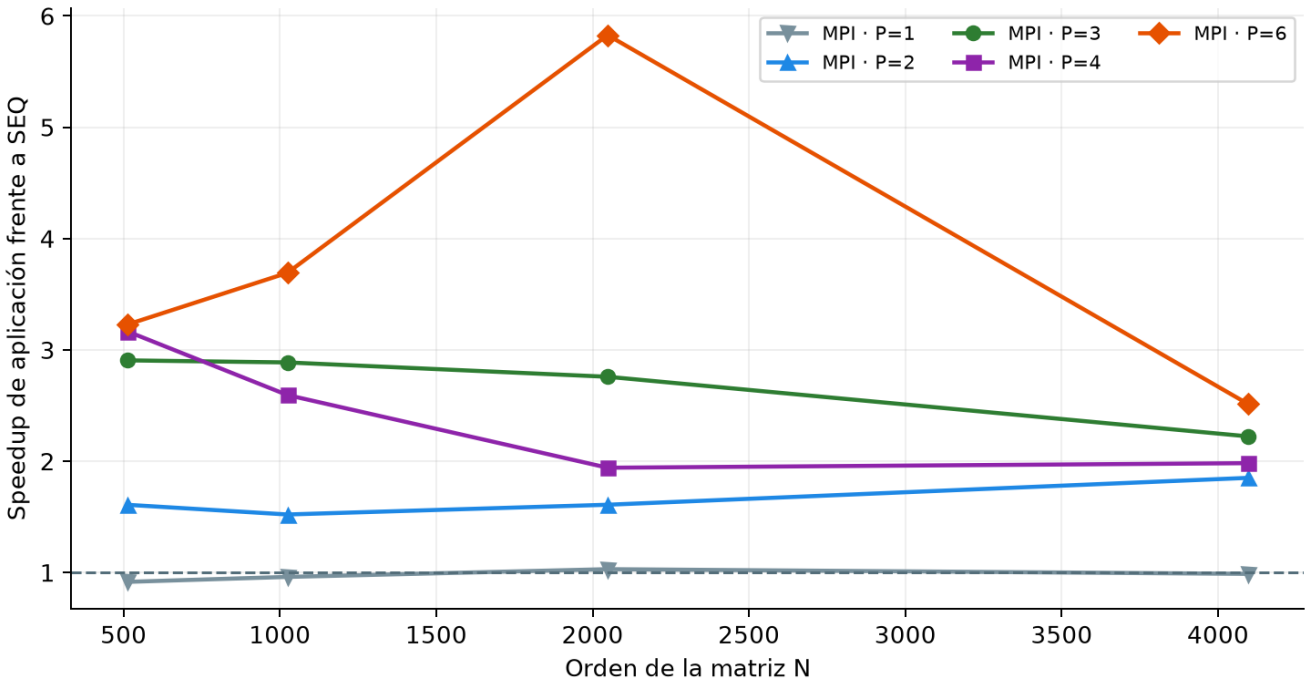


Figura 10. Speedup de aplicación para cada P en la campaña de escalabilidad. Las referencias se recalculan dentro de esta campaña; no se empalman con las del cruce.

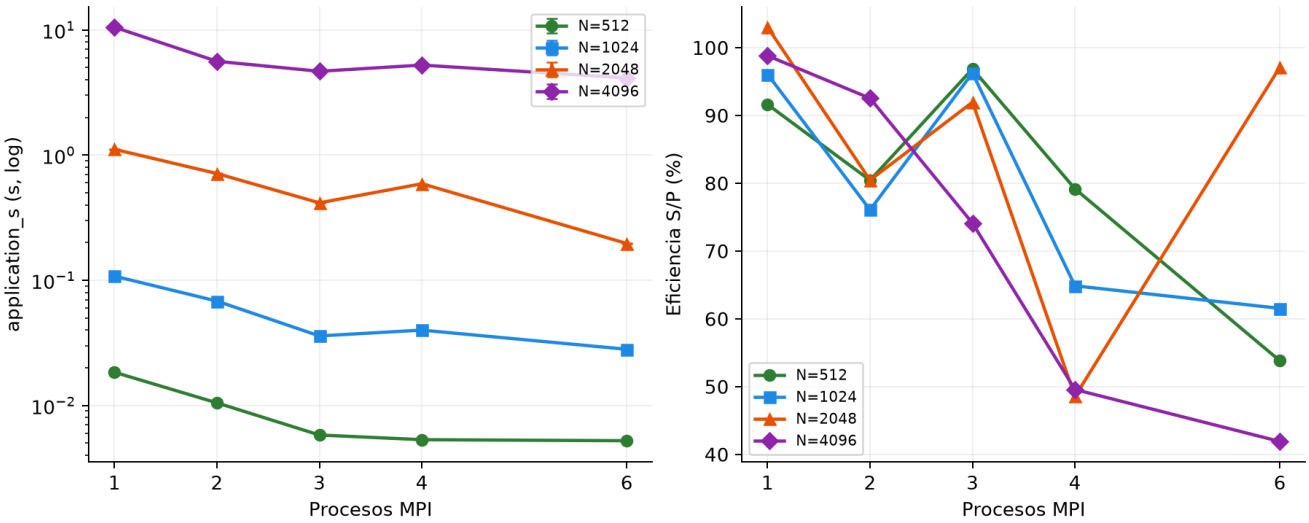


Figura 11. Tiempo de aplicación con Q1-Q3 y eficiencia S/P. Mantener N fijo y variar P permite estudiar escalabilidad fuerte dentro de la asignación.

El speedup de aplicación para P=6 alcanzó aproximadamente 3,23; 3,69; 5,83 y 2,51 para los cuatro tamaños. El valor de N=2048 no demuestra una causa específica como caché, y su descenso en N=4096 impide describir una mejora monótona con N. P=4 volvió a presentar casos peores que P=3. Comunicación, sincronización, ubicación, memoria y condiciones del entorno son factores plausibles, pero no fueron aislados causalmente.

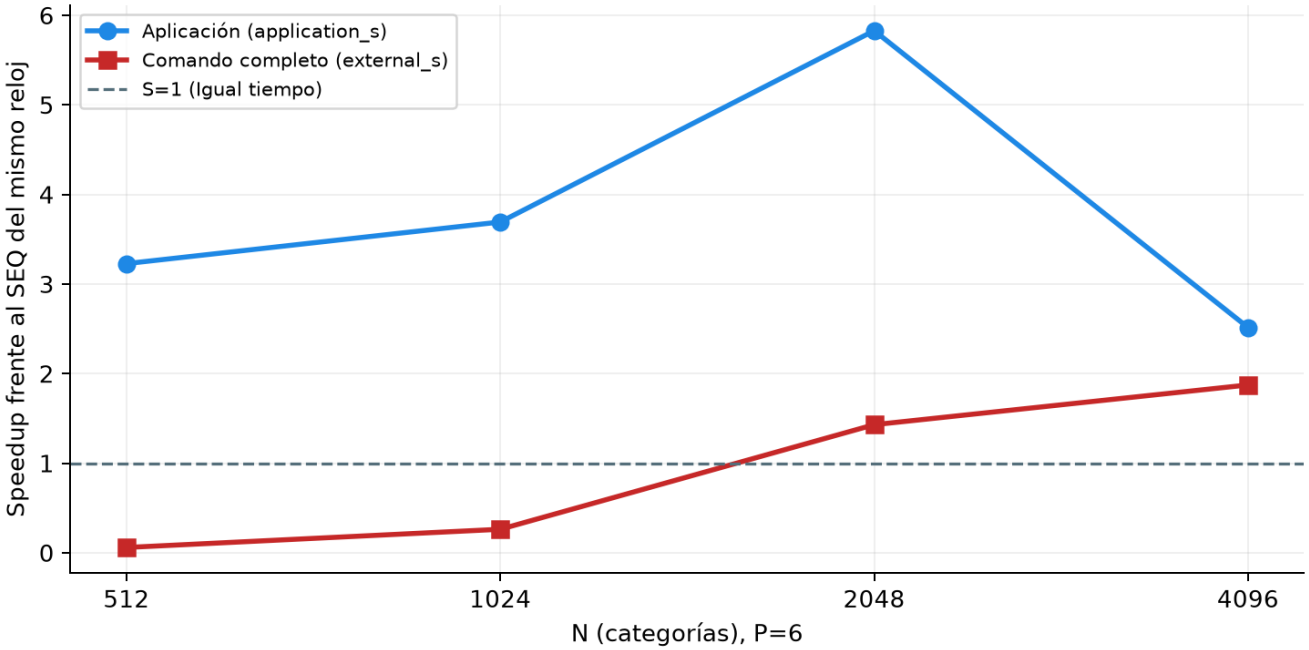


Figura 12. P=6 frente al secuencial propio: el mismo lanzamiento conduce a distintas conclusiones según la frontera temporal. La línea S=1 marca igualdad de medianas.

Para N=512 y N=1024 el comando completo MPI seguía perdiendo pese a acelerar la aplicación. En N=2048 y N=4096 la ventaja sobrevivió al reloj externo, con speedups aproximados de 1,43 y 1,87. Esos cocientes no deben presentarse como aceleraciones del kernel ni el primero como un umbral exacto de extremo a extremo: la grilla tiene cuatro tamaños separados.

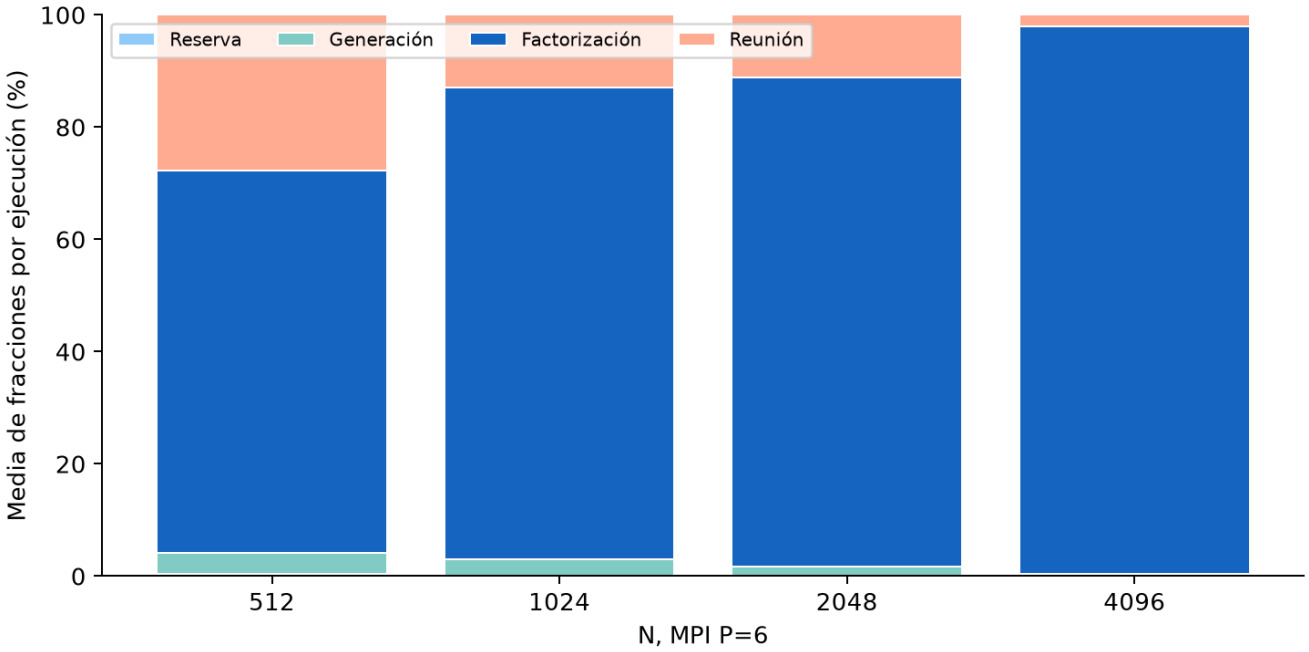


Figura 13. Composición de aplicación para P=6. Se calcula la fracción de cada fase por ejecución y luego su media, de modo que la barra suma 100 %. No se suman medianas para construir un total ficticio.

La evidencia respondió el objetivo universitario de distinguir rendimiento algorítmico y beneficio completo sin necesidad de agotar todos los procesos ofrecidos por el portal. Una asignación mayor permitiría otro experimento, pero no cambia retrospectivamente la cuota de esta campaña.

14. La referencia optimizada en el clúster

El entorno de biblioteca quedó identificado como LAPACK/LAPACKE 3.11.0 y OpenBLAS 0.3.34 con backend pthreads y selección de CPU Zen. El ejecutable fuerza un hilo y registra la comprobación. La variable OMP_NUM_THREADS=1 no demuestra que el candidato use OpenMP; el código propio no contiene regiones OpenMP y la biblioteca utilizada informa pthreads.

La campaña de referencia incluyó N=2048 y N=4096, seis observaciones por método dentro de compare_lapack.c. Un control N=512 se conserva aparte. Los métodos alternan la primera posición, con una preparación interna por método no exportada al CSV. La matriz original y un factor propio de referencia se preparan fuera del reloj; cada observación medida reserva, genera y factoriza una matriz nueva.

N	Reloj	C propio (s)	LAPACK (s)	Propio/LAPACK
2048	factor_s	1.060705	0.081292	13.048
2048	total_s	1.089732	0.110383	9.872
4096	factor_s	9.854616	0.589960	16.704
4096	total_s	10.269754	1.006013	10.208

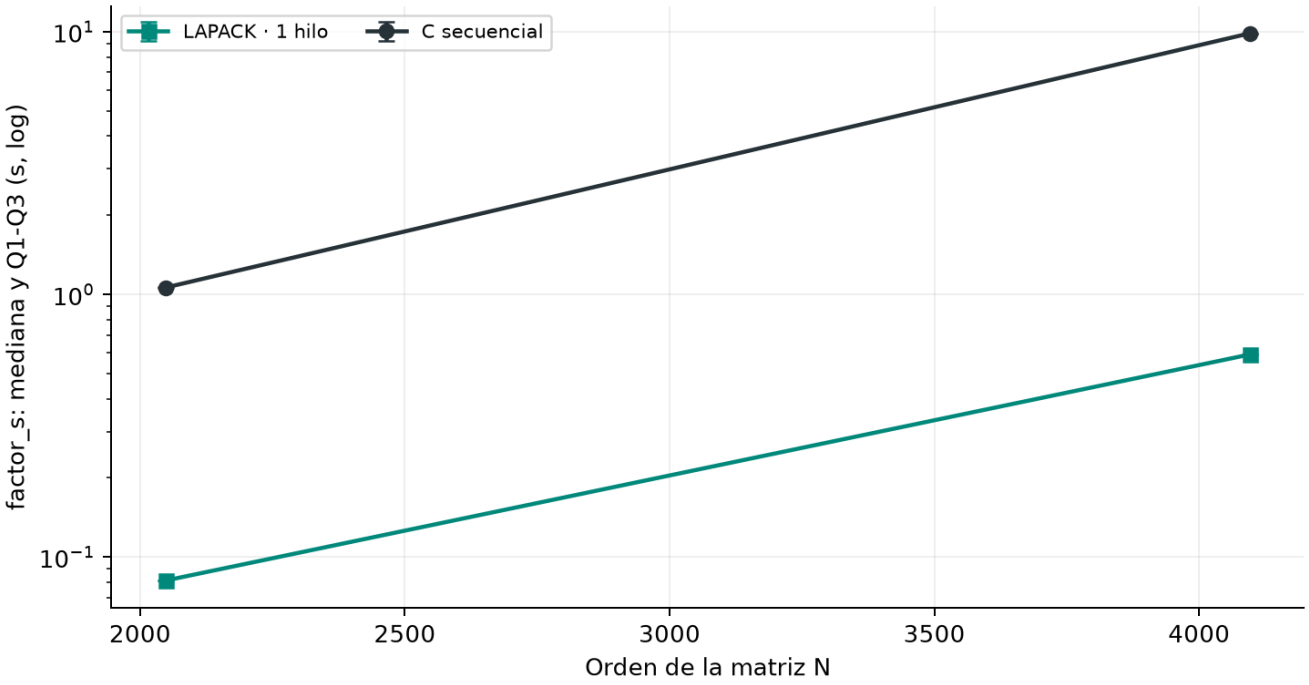


Figura 14. Medianas y Q1-Q3 de factor_s para C propio y LAPACK/OpenBLAS de un hilo, en su campaña común. Eje vertical logarítmico.

La ventaja de factorización de LAPACK fue de aproximadamente 13,05 veces para N=2048 y 16,70 para N=4096. En el total del banco fue 9,87 y 10,21. La relación en N=2048 fue del mismo orden que la observada localmente, pero no se compararon tiempos absolutos de dos máquinas como si fueran simultáneos.

El log de compilación registra una advertencia _Float16 con -Wpedantic en un encabezado de OpenBLAS. No es un error del cálculo propio. Las pruebas pequeñas registran PASS; los residuos y diferencias del factor cumplen el criterio. Los CSV principales no exportan valid ni código de salida, por lo que no se inventa un estado del shell aunque las comprobaciones numéricas sean satisfactorias.

La preparación mediante Conda y la reinstalación tras reiniciar la instancia forman parte del relato operativo recibido. Los archivos finales verifican la presencia y versiones de las dependencias, pero no contienen un historial íntegro de instalación ni una prueba independiente de qué directorios se restablecieron. La guía de reproducibilidad presenta esa distinción y recomienda verificar las dependencias de cada instancia.

15. Comparación final de problemas grandes

La referencia optimizada desplazó el foco hacia la capacidad del paralelismo para compensar un kernel propio menos eficiente. Se ampliaron los tamaños a N=6144 y N=8192 y se compararon C propio secuencial, MPI P=6 y LAPACK/OpenBLAS de un hilo. No se repitió toda la grilla de P, ya estudiada. Se conservaron seis observaciones útiles por método y tamaño, 36 en total; las dos preparaciones MPI aparecen en CSV y las cuatro preparaciones propias/LAPACK están implementadas dentro del banco y no se exportan.

La métrica principal es factor_s. El secuencial y LAPACK se alternan en un proceso con repeticiones internas; MPI utiliza lanzamientos separados. La campaña común, el generador y los fuentes coincidentes hacen pertinente comparar la fase matemática de factorización, pero no garantizan idéntico estado de caché ni idéntico contexto de ejecución. application_s MPI y total_s del banco se conservan únicamente como contexto.

N	Método	n obs.	Q1 (s)	Mediana (s)	Q3 (s)
6144	own	6	27.260189	27.269004	27.271326
6144	p6	6	16.090931	16.298454	16.492704
6144	lapack	6	1.898735	1.899152	1.899557
8192	own	6	72.001985	72.091515	72.124989
8192	p6	6	36.921419	36.953931	36.994156
8192	lapack	6	5.912865	5.915935	5.918062

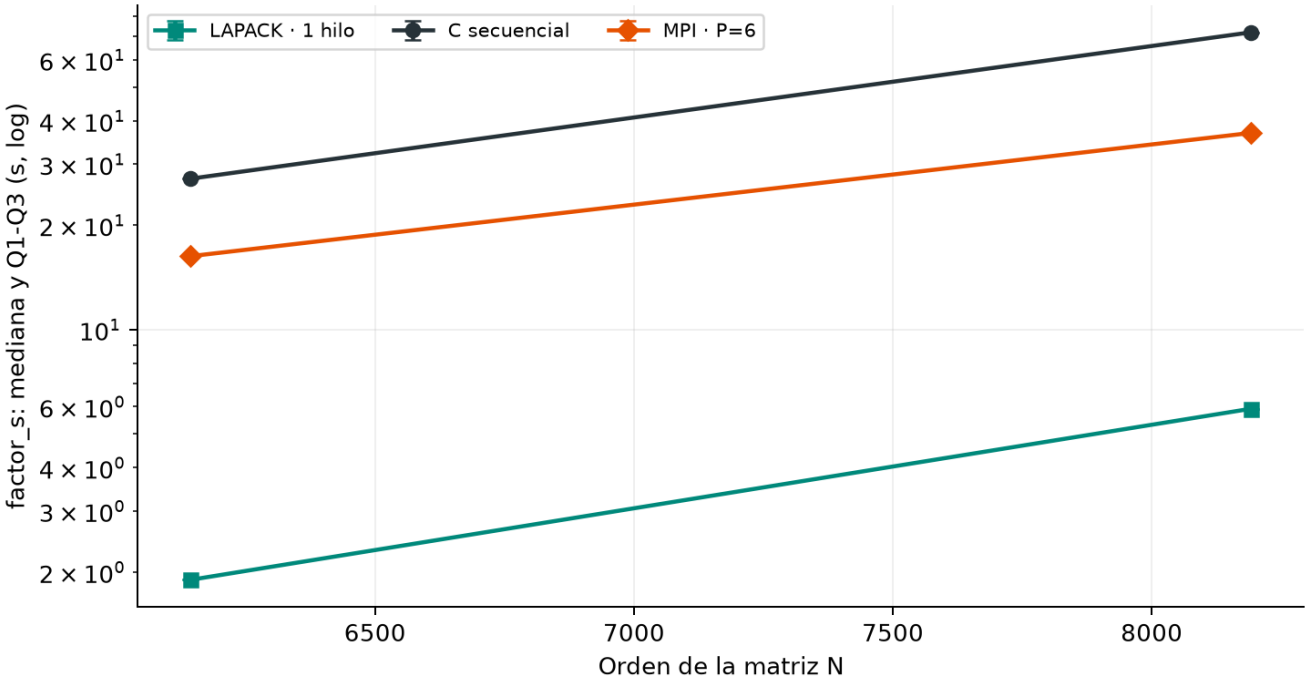


Figura 15. factor_s para los tres métodos en la campaña final, seis observaciones por grupo. Se muestran medianas y Q1-Q3; escala logarítmica.

N	C/MPI	E MPI %	C/LAPACK	MPI/LAPACK
6144	1.673	27.9	14.359	8.582
8192	1.951	32.5	12.186	6.247

MPI P=6 redujo el tiempo propio con speedups de 1,673 y 1,951, equivalentes a eficiencias respecto de esa base de aproximadamente 27,9 % y 32,5 %. Sin embargo, tardó 8,58 y 6,25 veces el tiempo de LAPACK de un hilo. La ganancia MPI es real dentro de la comparación; no compensó la diferencia de eficiencia del kernel local optimizado.

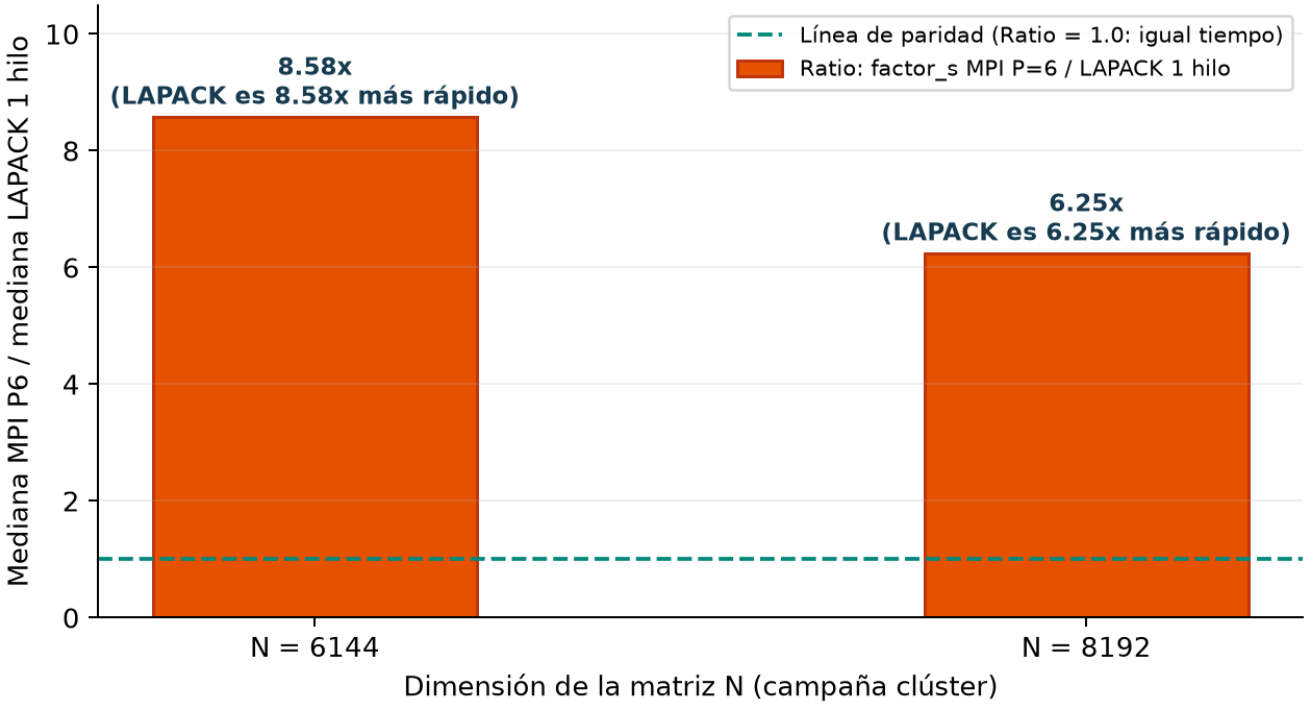


Figura 16. Cociente de medianas MPI/LAPACK en los dos tamaños finales. Un valor superior a uno significa que MPI tarda más.

La distancia relativa disminuyó entre esos dos puntos, pero la diferencia absoluta de segundos aumentó. No existe evidencia suficiente para extrapolar un cruce, predecir su tamaño ni afirmar una convergencia monótona. Hasta el mayor N ensayado, LAPACK/OpenBLAS de un hilo mantuvo menor mediana de factorización.

15.1. Observación separada sobre la generación

N	Método	Generación mediana (s)
6144	lapack	0.402331
6144	own	0.402347
6144	p6	0.132174
8192	lapack	3.978558
8192	own	3.980563
8192	p6	0.061364

La generación secuencial mostró un salto entre N=6144 y N=8192 que afecta al total del banco. El acceso simétrico por columnas y el stride asociado a una potencia de dos motivan una hipótesis de memoria/caché, pero no se midieron contadores para comprobarla. Se registra la anomalía sin atribuirle causalidad y sin mezclarla con el resultado principal de factor_s. Estudiarla sería una extensión, no una condición para cerrar esta comparación.

16. Corrección numérica e integridad de la evidencia

El residuo completo utilizado en problemas pequeños es ||A-LL^T||F/||A||F. Se reconstruye el producto con acumulación long double; que sea completo no significa aritmética exacta. Su costo de orden N^3 motivó limitarlo a pruebas pequeñas. En el candidato se exporta para N<=128 y se escribe -1 cuando no se calcula; -1 no es un residuo negativo medido.

Para tamaños grandes se utiliza el máximo de ||Ax-L(L^{T}x)||2/||Ax||2 sobre ocho vectores de signos con semilla 91827. Es una comprobación reproducible de costo $O(8N^2)$, no el residuo de Frobenius ni un certificado para todas las direcciones. El candidato también comprueba valores finitos y diagonal positiva. Los bancos de comparación contrastan además el factor con una referencia propia mediante el máximo de |L-Lref|/max(1,|Lref|) por elemento del triángulo inferior.

$$r = \frac{\|A - LL^T\|_F}{\|A\|_F}$$

El umbral operativo principal es 1e-12. Algunos primeros bancos exigían 1e-13 para la diferencia de factores, sin cambiar el umbral del residuo. Las matrices ensayadas pasan los controles; esto no demuestra estabilidad universal frente a mal condicionamiento. Se registran los máximos, incluyendo preparaciones exportadas y controles cuando forman parte del conjunto auditado:

Campaña	Filas auditadas	Residuo completo máx.	Proyectado máx.	Diferencia máx.
cierre_local_20260924	223	3.790e-16	1.611e-15	-
cierre_local_20260927	222	3.790e-16	1.611e-15	-
cluster_crossing	240	3.790e-16	5.764e-16	-
cluster_lapack	36	-	2.275e-15	6.595e-15
cluster_large	38	-	3.240e-15	8.866e-15
cluster_scalability	192	-	2.275e-15	-
left_right_mpi_20260922	320	1.213e-15	-	2.658e-15
memoria_20260921	216	1.213e-15	-	-

Las pruebas locales archivadas incluyen sanitizadores. En MPI se documentó una incompatibilidad de ASan durante MPI_Init con el componente memory/patcher y se utilizó una configuración de prueba con ese componente desactivado. La detección de fugas estaba desactivada; no se presenta como una prueba de ausencia de fugas ni se traslada ese ajuste a los benchmarks ordinarios.

La auditoría de paquetes verifica 113 entradas del manifiesto preformal; 493 del manifiesto global del cruce y nueve adicionales de procedencia; doce de procedencia en escalabilidad; cuatro hashes del entorno LAPACK; y 43 entradas del manifiesto final. La campaña de escalabilidad y la de LAPACK no incorporan manifiestos globales de los CSV. Sus hashes de recepción identifican los paquetes actuales, pero no sustituyen una firma o un manifiesto previo ausente. Los ejecutables incluidos se preservan como evidencia y no se ejecutan durante el análisis.

17. Condiciones del entorno y límites de atribución

Campaña	Delta períodos	Delta throttled	Delta throttled_usec
cruce	941	0	0
escalabilidad	5514	197	764111
final_grande	15888	1676	4376492

Los contadores de cgroup rodean campañas completas y pueden incluir actividad auxiliar. En el cruce no aumentaron los contadores de throttling. En escalabilidad y tamaños grandes sí hubo incrementos. No permiten asignar un costo a un P concreto, corregir los tiempos restándolo ni explicar por sí solos la anomalía de P=4. El diagnóstico preformal de N=4096 también registró incrementos, conservados en la bitácora.

Las campañas se realizaron dentro de una asignación de un host; no se ensayó comunicación entre nodos. Los diagnósticos de binding no garantizan exclusividad ni control NUMA de páginas. La rotación anunciada de algunas campañas del clúster no puede auditarse por completo cuando falta el script; la alternancia de compare_lapack.c, en cambio, está presente en el código archivado y en los campos de orden.

Se utilizaron seis o siete repeticiones por grupo en las campañas formales principales. Medianas y cuartiles describen esa muestra, no intervalos de confianza. No se realizaron pruebas de hipótesis ni se estimó incertidumbre inferencial de los cocientes. Las repeticiones de una misma matriz caracterizan variabilidad temporal, no una población de matrices independientes.

La validación centralizada, los buffers completos y la salida reunida definen el caso estudiado y limitan su escalabilidad de memoria. El candidato carece de entrada de matrices externas, distribución 2D, almacenamiento triangular compacto y kernel BLAS-3. Esas decisiones de alcance se describen para interpretar los resultados, sin convertir cada extensión posible en un requisito pendiente.

18. Conclusiones

La investigación confirmó que la conveniencia de MPI depende del tamaño, la implementación local y la frontera de medición. El análisis de memoria cambió primero la selección secuencial: copiar la columna activa compensó su costo y permitió adoptar right-looking con vector. El diseño MPI requirió además combinar reparto cíclico y vector local; una distribución teóricamente favorable no había sido suficiente en la primera versión.

La generación distribuida redujo el costo de preparar los datos, pero la mejora de una fase no se trasladó íntegramente al flujo. La exploración de propiedad por grupos de columnas tampoco produjo una regla estable: la ventaja inicial de b=4 desapareció en otra sesión y se mantuvo b=1. Conservar esos resultados evita seleccionar una variante por una única medición favorable.

En el clúster, el primer N ensayado que cumplió el criterio descriptivo de mejora de aplicación fue 192 con P=3. Los distintos P cruzaron en tamaños distintos y las curvas no fueron siempre monótonas. La campaña mayor demostró que acelerar la aplicación no implica terminar antes el comando: P=6 perdió en el reloj externo para N=512 y N=1024, pero ganó para N=2048 y N=4096.

LAPACK/OpenBLAS puso en perspectiva la ganancia del paralelismo propio. Con un solo hilo, su factorización fue sustancialmente más rápida. Al ampliar a N=6144 y N=8192, MPI P=6 mejoró al secuencial propio, pero no alcanzó a LAPACK. No se concluye que LAPACK sea un algoritmo mejor que

MPI: una biblioteca local optimizada y un mecanismo de distribución son componentes distintos. La evidencia muestra que repartir un kernel menos eficiente no compensa necesariamente su desventaja local.

El alcance experimental queda cerrado con esas respuestas, su validación y sus límites. No es necesario ampliar recursos ni realizar otra campaña para sostener las conclusiones actuales. Una ampliación debería responder una pregunta nueva y conservar la comparación contemporánea, los relojes explícitos y la evidencia original.

19. Continuación técnica razonable

La primera extensión sería mejorar la reutilización de datos del kernel mediante un Cholesky realmente bloqueado y operaciones BLAS-3, manteniendo los tests de corrección y comparando la fase de factorización. El antecedente de LAPACK justifica estudiar esa dirección, pero no garantiza qué fracción de su ventaja reproduciría una nueva implementación.

OpenMP constituye una continuación importante para paralelismo de memoria compartida. Una versión híbrida podría usar MPI entre nodos o dominios y menos procesos dentro de cada nodo, con hilos OpenMP para trabajo local. Habría que mantener constante el presupuesto total de recursos, controlar afinidad y evitar sobreasignar hilos si también se usa BLAS multihilo. No se implementó esa versión ni se anticipa una ganancia medida. Especificación OpenMP 5.2.

Otras extensiones son reducir almacenamiento y buffers, distribuir la validación, estudiar NUMA, medir contadores para la anomalía de generación y examinar la no monotonicidad de P=4. Las pruebas multinodo permitirían evaluar costos de red que esta campaña intranodo no identifica. ScaLAPACK, con distribuciones 2D por bloques, sería una referencia distribuida profesional para otra comparación; no participó en los experimentos presentes. Guía de ScaLAPACK.

Para un trabajo universitario, la continuación prioritaria es convertir las conclusiones en una defensa clara: justificar el candidato, distinguir los relojes y explicar por qué la referencia optimizada ganó. Las extensiones anteriores pueden constituir un proyecto posterior, con una hipótesis y una campaña acotadas.

20. Guía de lectura de la entrega

El README permite compilar y ejecutar una prueba breve. Metodología experimental fija estadísticos y relojes; reproducibilidad reúne entorno, comandos y límites de auditoría; el inventario técnico distingue candidato, bancos y herramientas. MANIFEST y los CSV de procedencia relacionan archivos originales y copias. Las tablas completas están en data/processed; los gráficos se publican en PNG y SVG. Los informes históricos se conservan en archive/docs_etapas y no constituyen la estructura de este relato.

Anexo A. Reconstrucción histórica y procedencia

La evidencia principal se encuentra en data/raw/local y en cinco paquetes originales de data/raw/cluster. Los análisis normalizados, las tablas y los gráficos se regeneran con scripts/analyze_results.py. Cada observación procesada incluye campaña, subgrupo, archivo de origen y fila del CSV. Los cuartiles son inclusivos y los cocientes se calculan con las medianas de la misma campaña y del mismo reloj. Los resúmenes históricos se preservan, pero no sustituyen a los CSV originales.

Existía un prototipo previo, cholesky_final_hpc.c, con paneles de tamaño 64, kernels escalares y una selección de estrategia basada en un modelo. Ese antecedente utiliza otro generador, otra validación y otra frontera temporal. Además, sus scripts describían argumentos para forzar estrategias que el programa no interpretaba: el código solo utilizaba el argumento N y elegía internamente la estrategia. La rama 2D era una predicción con retorno a 1D, no una implementación distribuida 2D. Por esas diferencias, sus tiempos no se incorporaron a las comparaciones de la investigación posterior. El antecedente se conserva en archive/antecedentes con esta salvedad.

La reconstrucción verificable comienza con los ensayos de septiembre conservados en desde_cero, ahora organizados por procedencia. Un documento inicial registra una implementación didáctica Python y 21 observaciones; sus fuentes Python no están presentes en el árbol actual. Se preservan las mediciones y el entorno sin reconstruir código inexistente ni convertir esos tiempos en base del speedup de C. La investigación de rendimiento que sigue utiliza generación y factorización en C; Python procesa la evidencia.

Los documentos antiguos describen decisiones todavía abiertas en su fecha, como llevar el programa al clúster o mantener b=4 como candidato. El informe actual reconstruye su resolución posterior y no convierte esas frases históricas en pendientes actuales. Las discrepancias y los límites de auditoría se detallan en reproducibilidad.